

RemoteSensing with R

Felipe Barros (f.barros@iis-rio.org)

2 de abril de 2016

Proposta de análise da cobertura (principalmente florestal) do município do Rio de Janeiro em diferentes anos, através de ferramentas espaciais do **R**.

Aqui apresentarei apenas a análise para um ano: 2006.

A proposta é fazermos uma classificação não supervisionada baseada em estatística espacial, para os anos pertinentes aos projeto **FAPERJ Mutirão de reflorestamento**. A partir da classificação não supervisionada, podemos atribuir a cada classe, a sua respectiva cobertura/uso.


Com isso:

1. Ganharemos tempo
2. Teremos todo o processo documentado por script e funções do **R**
3. Teremos a possibilidade de ampliarmos a gama de análise dos dados

Dados básicos da análise

1. Imagem de satélite
2. Área de estudo

```
# Plotting input data
plotRGB(rj_2016, r=4, g=3, b=2, stretch='hist')
plot(rj, add=TRUE)
```



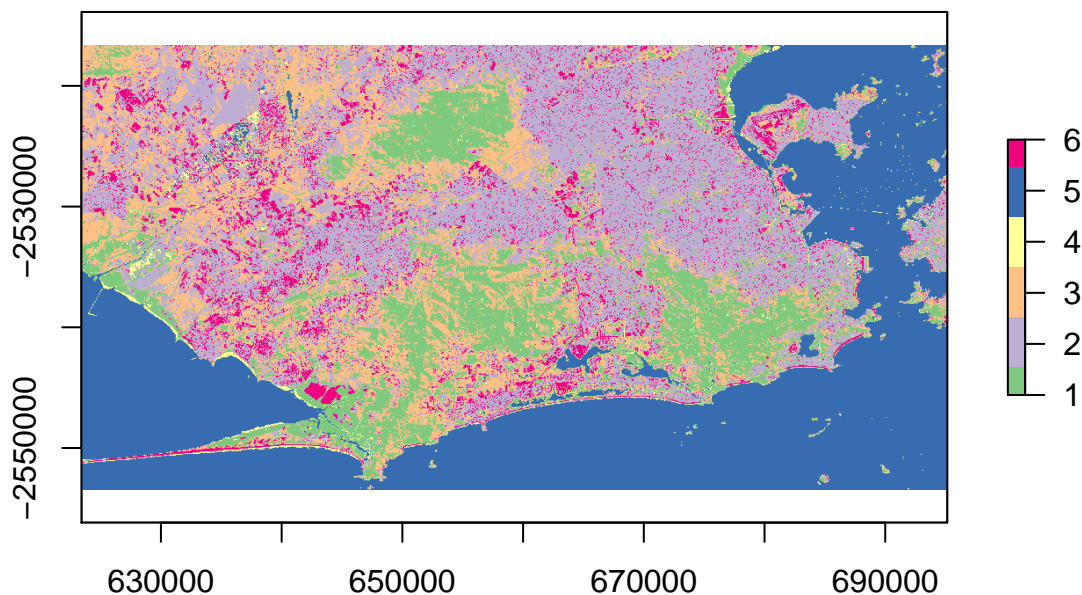
Algoritmos de classificação não supervisionada

Na função que criamos, podemos usar dois algoritmos básicos: **Kmeans** e **randomForest**; No exemplo dado, foi usado apenas o algoritmo **Kmeans**, que tem como vantagem o uso de todos os pixels da imagem na análise de agrupamento.

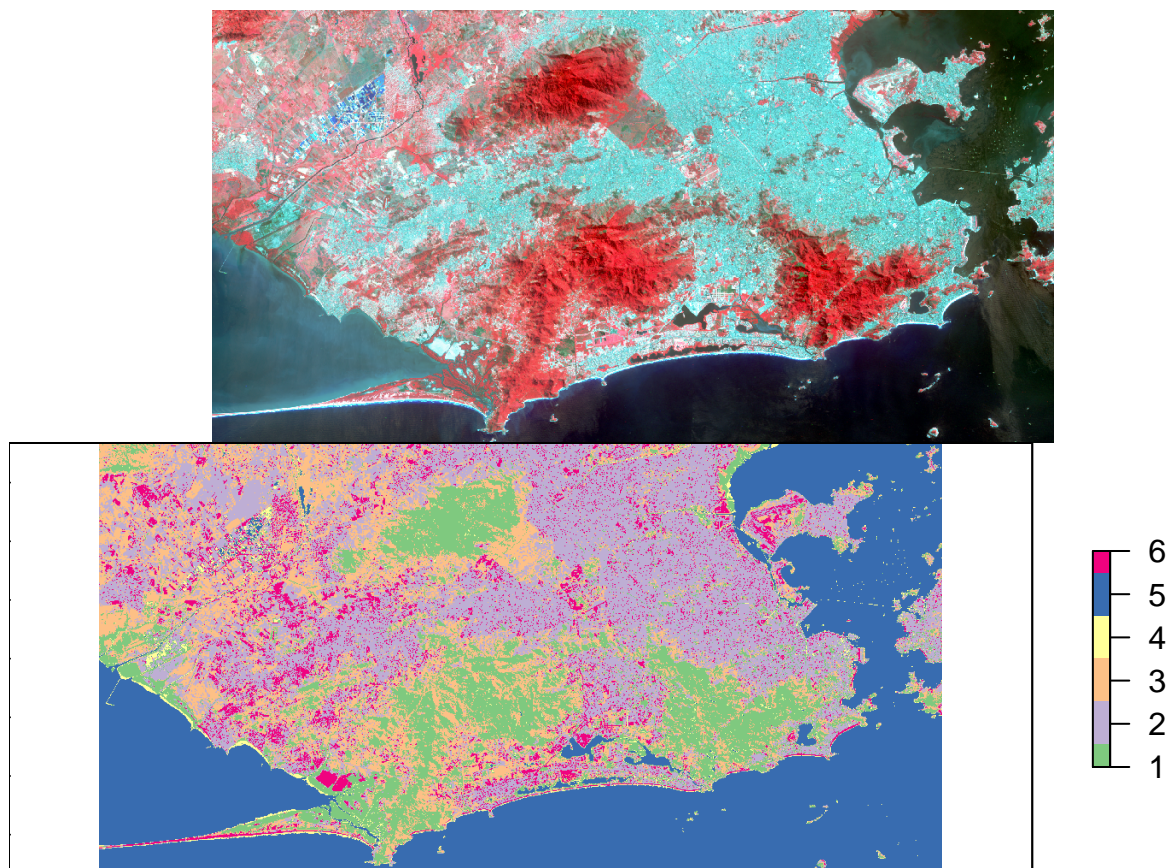
```
# Running cluster analysis (Automatic classification)
source('~/Projetos/SegmentationFCT/segmentation.R')
args(segmentation)
segmentation(envLayer = rj_2016_2, studyArea = rj, projName = "RJ_2016",
             randomforest = FALSE, random.pt = NULL, Kmeans = TRUE, ngroup = 6,
             polygonize = FALSE, seed = 123)
```

Resultado

```
# Result
RJ_2016_seg <- raster('./km_segmentation_RJ_2016.tif')
plot(RJ_2016_seg, col=pallete)
```



```
# Result
par(mfrow=c(2,1))
plotRGB(rj_2016, 4, 3, 2, stretch='hist')
plot(RJ_2016_seg, col=pallete)
```



Basta portanto, identificar a cada classe criada o respectivo uso e/ou cobertura da terra. O tempo de processamento não é grande. E, depois, podemos fazer uma mascara para vermos a evolução das áreas do mutirão, já que estamos analisando todo o município.

Visualmente, podemos ver que:

1. **classe 1**, com cor **verde**: poderia ser classificada como **áreas florestais**
2. **classe 2**, com cor **roxa** (ou coisa parecida): seriam as **áreas urbanas**
3. **classe 3**, com cor **laranja**: seriam áreas florestais, mas com alguma diferença da **classe 1**
4. **classe 4**, em **amarelo**: pouco aparecem, seriam **áreas de areia**
5. **classe 5**, em **azul**: seriam **corpos d'água**
6. **classe 6**, em **vermelho**: **áreas urbanas**, mas com resposta diferente da **classe 2**

Análise dos resultados

Um pequeno exemplo de pós processamento é vermos como cada classe identificada está se comportando em relação às bandas da imagem de satélite (resposta espectral).


O exemplo dado é muito básico, mas é possível evoluimos bastante nisso.


```

# Analysing band relation with category
graph <- addLayer(rj_2016, RJ_2016_seg)
class.df <- (as.data.frame(graph))
head(class.df)
colnames(class.df)<-c('um', 'dois', 'tres', 'quatro', 'cinco', 'seis', 'class')

#Plot
library(ggplot2)
ggplot(class.df, aes(x=um, y=dois, colour=as.factor(class))) + geom_point()
ggsave('./class_analysis.png')

```



Perspectivas futuras

Ainda não pude pesquisar, mas imagino que existam pacotes específicos do **R** para Sensoriamento Remoto, que poderão nos ajudar bastante nas análises.

Acho que assim que terminar com as modelagens para Mata Atlantica, poderíamos ver isso.